

# 基于图卷积神经网络的地铁客流预测方法

陈镇元

(广东工业大学,广东 广州 510006)

**摘要:**随着社会经济的快速发展和城镇化的推进,大城市的人口不断增加,交通出行的压力变得越来越大,因此轨道交通成了人们出行的主流方式。如何准确地做好地铁客流量预测工作,对轨道交通发展具有重要意义。本文提出一种基于图卷积神经网络的地铁客流预测模型,该模型能够有效捕捉地铁网络中复杂的空间依赖和时间依赖,提升预测精度。

**关键词:**图卷积神经网络;客流预测;方法

**中图分类号:**TP183,U231+.92

**文献标识码:**A

**文章编号:**2096-4390(2021)03-0088-02

## 1 概述

随着国内外交通运输的飞速发展,关于城市轨道交通客流预测的研究逐渐引起了学者的关注。地铁作为现代大城市一项极其重要的交通工具,与其他交通运输方式相比,具有效率高、运输量大、污染小、稳定安全以及方便快捷等众多特点,受到人们的青睐,是缓解城市运输压力的有效方式。由于地铁受到越来越广泛的应用,人们对其的需求亦日益增加,因此,如何准确地做好地铁客流量预测工作,不仅对地铁运营服务的提高,而且对人们的出行方式选择具有重要意义。客流预测是地铁系统的重要组成部分,特别是城市地铁的近期客流量准确预测,有着十分重要的作用。第一,客流预测可以帮助地铁管理进行更合理的配置,包括地铁工作人员的调配,减少乘客拥挤,布置疏导客流的准备措施,对发生事故时的应急决策等,以此提高地铁系统的服务质量。第二,客流预测可以给人们作为参考,选择更为高效和安全的出行方式。第三,客流预测对后续轨道交通的建设规划和工程投资具有重要的战略价值。第四,客流预测对地铁周边的商业布局具有经济意义。

现阶段关于短时客流预测的方法主要分为以下几类:基于统计学理论为基础的预测模型,包括时间序列模型和卡尔曼滤波模型等<sup>[1]</sup>;基于神经网络与传统机器学习为基础的预测模型<sup>[2]</sup>;基于非线性理论为基础的预测模型<sup>[3]</sup>;基于各种理论的组合模型以及基于深度神经网络和深度学习的预测模型等。这些方法都是根据客流特征进行分析,利用交通理论或者机器学习和深度学习的算法建立预测模型。然而,对于地铁客流预测是非常具有挑战性的,因为客流量会受到复杂的空间依赖和时间依赖的影响,是一个非常棘手但又必须要解决的问题。随着近几年图论的发展以及图卷积神经网络的提出,对地铁客流预测这一问题有了新的解决思路。

## 2 方法介绍

近年来,图神经网络(graph neural network,GNN)也受到了越来越多学者的注意。图神经网络的概念首先由 Gori 等人<sup>[4]</sup>(2005)提出,并由 Scarselli 等人<sup>[5]</sup>(2008)进一步阐明。图是一种数据结构,它为一组对象(节点)及其关系(边)建模。图神经网络是一种连接模型,它通过图的节点之间的消息传递来捕捉图的依赖关系。与标准神经网络不同的是,图神经网络保留了一种状态,可以表示来自其邻域的具有任意深度的信息。图神经网络 GNN 是在图域上运行的基于深度学习的方法。GNN 在社

交网络、知识图谱、推荐系统、道路交通、生物分子结构等各个领域有着很大的应用前景。GNN 在对图节点之间依赖关系进行建模的强大功能,使得与图分析相关的研究领域取得了突破。当信息在图的节点之间传播时 GNN 会捕捉到图的独立性。GNN 以其令人信服的性能和较高的可解释性,近年来已成为一种广泛应用的图论分析方法<sup>[6]</sup>。传统机器学习所用到的数据是欧式空间的数据,CNN 卷积神经网络等在结构规则的欧式空间等数据上效果显著,但是在非欧氏空间比如图结构数据,就难以选取固定的卷积核来适应整个图的不规则性,如邻居节点数量的不确定和节点顺序的不确定。由于传播过程对于图网络的训练是至关重要的,目前主流的方法是将 CNN 卷积应用到图结构上,也就是图卷积网络(graph convolutional network,GCN)。图卷积网络的方法可以分为频谱方法和空间方法两大类,本文介绍的是频谱方法。

给定一个图  $G=(V,E,A)$ ,其中  $V$  表示图的节点集合, $E$  表示图的边集合, $A \in R_{n \times n}$  是邻接矩阵。对于图  $G$  的拉普拉斯矩阵  $L$  定义为  $L=D-A$ ,正则化的拉普拉斯矩阵为  $L=I_n-D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$ 。其中  $I_n \in R_{n \times n}$  是单位阵, $D \in R_{n \times n}$  是顶点的度矩阵  $D_{ii}=\sum_j W_{ij}$ 。拉普拉斯矩阵其谱分解为  $L=U\Lambda U^{-1}$ ,其中  $U=[u_1, \dots, u_n]$ , $\Lambda=\text{diag}([\lambda_1, \dots, \lambda_n])$ 。对于一个输入  $x \in R^n$  在图中的傅里叶变换定义为  $\hat{x}=U^T x$ ,其傅里叶逆变换定义为  $x=U\hat{x}$ 。这样, $x$  与卷积核进行卷积就可以写成  $g_\theta * x = U g_\theta U^T x$ , $g_\theta = \text{diag}([\theta_0, \dots, \theta_{n-1}])$ 。由于  $g_\theta$  的计算复杂度较高,Kipf 等人<sup>[7]</sup>引入了一种一阶近似 ChebNet,将卷积公式近似为  $g_\theta * x = \theta_0 x - \theta_1 D^{-\frac{1}{2}} A D^{-\frac{1}{2}} x$ 。为了防止过拟合,假设  $\theta_0 = \theta_0 - \theta_1$ ,图卷积的定义就近似为

$$g_\theta * x = \theta \left( I_n - D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \right) x = \theta \left( \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} \right) x$$

其中  $\tilde{A}=A+I_n$  和  $\tilde{D}_{ii}=\sum_j \tilde{W}_{ij}$  重新归一化得到的,即图上加上自环。再加上一个激活函数,就可以得到论文的快速卷积公式:

$$H^{(l+1)} = \sigma \left( \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^l \right)$$

$W$  就是参数  $\theta$  的参数矩阵。

## 3 模型建立

我们可以将整个城市的地铁网络用图  $G=(V,E,A)$  来表示,设定每一个地铁站为一个顶点  $V$ ,地铁线路为边  $E$ ,定义一个邻接矩阵  $A \in R_{n \times n}$  来表示各个站点间的联通关系。因此整个地

铁网络可以用一个图  $G$  来描述,其中每个顶点  $V$  都有一个由客流历史值组成的特征向量。利用 GCN 就可以捕捉地铁网络之间的不规则的时空依赖关系。针对每个顶点,使用一阶邻接进行卷积运算,可以得到该顶点与其一阶相邻节点之间的空间依赖关系。通过一层 GCN 网络以后,该节点的信息会被其邻近节点的信息更新。因此,经过 GCN 网络以后,可以获取到客流数据的时间特性和空间特性。在地铁网络中,高阶邻接可以通过多个低阶邻接累积,由于一个卷积层只能捕获到相邻站点之间的关系,为了获得远处站点的节点信息,需要叠加多个 GCN 卷积层,以提取更远处节点的节点信息。最后加入全连接模块,使用修正线性单元 ReLU 作为激活函数。图 1 展示了图卷积神经网络的基本框架。




图 1 图卷积神经网络基本框架

#### 4 实验结果与分析

本文采用的数据集为天池全球城市计算 AI 挑战赛的公开数据集,数据集包含了 2019 年 1 月 1 日至 2019 年 1 月 25 日的地铁刷卡数据记录,预测未来一天以 10 分钟为单位的各时段各地地铁站的出站人数和进站人数,采用平均绝对误差 (Mean Absolute Error, MAE) 进行评估,最后再对两者取平均得到评分。我们将图卷积神经网络模型与其他著名机器学习模型 K 最近邻 (KNN), 支持向量回归 (SVR) 以及另外一种著名的集成模型 Xgboost 进行对比,对比结果如表 1 所示。

表 1 MAE 结果对比

模型名称	MAE 值
KNN	17.6
SVR	16.6
Xgboost	14.5
GCN	14.1

由表 1 可知,相较于传统的 KNN 和 SVR 模型,GCN 模型表现出较优的性能,相较于性能较优的 Xgboost 模型相比,GCN 也具有不错的表现性能,因其能够捕获路网间的时空依赖关系,能有效提高预测的准确度。本文采用的 GCN 模型是比较基础的图卷积模型,加以改良后其预测效果还能够进一步提升。

#### 5 结论

图卷积神经网络是近年来新提出的一个研究方向,由于它是在图域上运行的基于深度学习的方法,这使得它在处理推荐系统、电子交易、分子结构,交通网络等图形网络结构有着天然的优势,未来具有很大的发展空间。本文使用了图数据的分析方法,利用地铁的历史刷卡数据,并根据现实的城市地铁网络,将其转换为图,并使用图卷积神经网络捕捉地铁网络中不规则的时空依赖关系,建立基于图卷积神经网络的地铁客流预测模型,实现对地铁短时客流的准确预测,模型表现出了不俗的性

能。后面将对预测模型的结构和组成进行进一步优化,以更好地捕获路网的时空特性,提升预测效果。

#### 参考文献

- [1]Ding A L, Zhao X M, Jiao L C. Traffic flow time series prediction based on statistics learning theory[C]//Proceedings. The IEEE 5th International Conference on Intelligent Transportation Systems. IEEE, 2002: 727- 730.
- [2]Zheng W, Lee D H, Shi Q. Short-term freeway traffic flow prediction: Bayesian combined neural network approach [J]. Journal of transportation engineering, 2006, 132(2): 114- 121.
- [3]Zhao S Z, Ni T H, Wang Y, et al. A new approach to the prediction of passenger flow in a transit system[J]. Computers & Mathematics with Applications, 2011, 61(8): 1968- 1974.
- [4]Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains[C]//Proceedings. 2005 IEEE International Joint Conference on Neural Networks, 2005. IEEE, 2005, 2: 729- 734.
- [5]Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1):61- 80.
- [6]Zhou J , Cui G , Zhang Z , et al. Graph Neural Networks: A Review of Methods and Applications[J]. 2018.
- [7]Kipf T N , Welling M . Semi-Supervised Classification with Graph Convolutional Networks[J]. 2016.