

基于深度时空网络的地铁站点客流短时预测

□ 黎旭成, 彭逸洲, 吴宗翔, 陈振武

(深圳市城市交通设计研究中心股份有限公司, 深圳 518000)

摘要: 为提升城市轨道交通站点短时客流预测精度, 探讨其高峰客流集中, 客流、区域人口密度间存在时空关联的特点, 并针对性地建立了一种基于深度时空网络的城市轨道交通网路尺度下的站点客流短时预测模型。模型用卷积神经网络捕捉轨道站点之间的空间关联, 融合了热点区域人数等因素作为外部特征, 再用长短期记忆网络提取时间序列中的时间关联。选取深圳市轨道交通网络作为案例, 基于深圳地铁客流数据, 对全部站点的进、出站客流进行预测。通过与四种常用预测方法比较, 验证了该方法的有效性和精度。

关键词: 短时客流预测; 城市轨道交通; 时空关联分析

中图分类号: U491

文献标识码: A

文章编号: 1671-3400(2020)08-0055-07

Short-term Forecast of Metro Station Passenger Flow Based on Deep Spatial-temporal Network

LI Xucheng, PENG Yizhou, WU Zongxiang, CHEN Zhenwu

(Shenzhen Urban Transport Planning Center Co., Ltd, Shenzhen 518000, China)

Abstract: To improve the accuracy of short-term forecast of metro station passenger flow, this paper discussed its highly concentrated and spatial-temporal dependent characteristics, showing passenger flow is relevant to region population. a forecasting model based on deep spatial-temporal network is developed accordingly. Convolutional neural network (CNN) is applied to capture the spatial dependency between stations. Long short-term memory network (LSTM) is applied to capture the time dependency in the time series. Further, population in region of interests and holidays are incorporated as external features. Experiments on Shenzhen Metro well demonstrate the effectiveness and precision of the proposed model against 4 common baselines.

Keyword: Short-term passenger flow forecast; Urban rail transit; Spatial-temporal dependency analysis

0 引言

城市公共交通需求量的精准掌握是实现智慧城市管理的一大关键点。对于人口密度较高的城市来说, 城市公共交通中的轨道交通, 是城市公共交通的主干线, 客流运送的大动脉, 承担了高峰期大量的出行需求。轨道交通的需求量具有明显的时空特征, 其时空特征主要体现在客流上, 而客流反映了交通需求量的变化。以对轨道站点客流来说, 其在空域上表现为客流量的分布和客流的方向, 乘客总是在不同的站点间进出, 不同站点的进站、出站客流之间存在相关性, 称之为空间关联; 其

在时域上又表现为每条线路、每个站点的客流量随时间在有规律地不断变化, 当前时段的客流与前序时段的存在相关性, 称之为时间关联。因此, 可以利用城市轨道交通网客流量的时空特征, 精准预测未来短期内的轨道交通出行需求量。

目前的需求预测方法主要包括基于统计分析的参数化方法和基于机器学习、深度学习等的非参数化方法: 基于统计分析的方法, 如自回归移动平均模型 (ARIMA)^[1]、高斯过程^[2]、隐马尔可夫链^[3]等, 能提取出单独的线路或站点随时间变化的规律, 但没有考虑站点间的空间联系, 对于大型的网络, 这些方法往往需要建立成百上千个模型来对各个站点单独进行预测; 基于深度学习的方法, 由于借助近年来的大规模的多维数据, 灵活性高、泛化和学习能力强, 预测精度高。一方面的做法是运用循环神经网络 (RNN) 来预测时间序列

收稿日期: 2020-05-18

第一作者简介: 黎旭成 (1988-), 男, 汉族, 广西南宁人, 博士, 主要研究方向: 交通大数据、智能交通、交通需求。

[4], 解决反向传播中的梯度问题, 适合提取时间特征, 另一方面采用卷积神经网络 (CNN) [5], 适合提取空间、时间特征。近些年将 CNN 和 RNN 结合使用的模型大量出现, 如 Yao^[6] 的深度多视角时空网络 (DMVST-Net) 通过长短期记忆网络 (LSTM) 提供时间视角, CNN 提供空间视角, 对时空关联进行提取。但这些方法大多对空间进行规则划分, 不同位置的变量间相关性与其空间距离挂钩, 运用场景与地铁线网有较大差异, 对于地铁线网来说, 因为轨道站点间的客流不符合“空间距离越近、相关性越高”这个假设, 站点间的空间相关性不适合直觉地简化为直线距离或是线网距离。各个站点的出站客流和进站客流, 在一定范围内的时空上都是相关的。

得益于移动互联网和大数据采集技术的发展, 手机信令、手机定位等数据可以反映城市人口在时间、空间上的迁移和聚集。本文发现热点区域的人群聚集与轨道交通的需求存在较强的相关性, 可以用于短时客流预测的依据。因此, 本文建立了一种考虑热点区域人数的基于深度学习的多站点短时客流预测模型, 利用深圳市地铁站点客流数据, 对模型进行了验证。

1 轨道交通站点客流时空特征分析

1.1 时空关联性

虽然轨道交通的客流存在明显的季节性规律, 但在短时客流预测的实际运用中, 会利用当季数据进行模型

训练, 更新模型, 可以让模型很好地适用于当季客流变化规律的预测, 因而这里只对客流的周规律和日规律进行分析。

以深圳市轨道交通客流为例, 展示了线网客流在 2019 年 3 月第 2 周、第 3 周的变化规律, 可以看出客流基本呈现工作日、周六、周日 3 种形态。工作日客流集中于早晚高峰; 周六则趋向于工作日的特征, 不过客流时间分布更为均衡; 周日客流最为均衡, 峰值客流较低。客流高峰的出现存在明显的周变规律, 但每周的客流还是存在较大的局部波动 (见图 1)。

日规律的把握是短时客流预测的重点, 大型城市往往具备多个中心, 存在若干职、住聚集区域, 站点间的客流关联会比较复杂。以深圳市客流最大的就业类热点车站之中的车公庙站、高新园站, 和居住类热点车站中的坪山站、五和站为例, 进行日规律分析。他们在 2019 年 3 月 4 日星期一的客流 (见图 2), 其具备典型工作日客流的特征。可以看到: 就业类热点车站早高峰集中出站、晚高峰集中进站特征较平日更为明显; 同类站点的客流其上升、下降时间点基本一致, 同一时间不同地方的站点的客流具备关联性; 早高峰居住热点的进站客流高峰先于就业热点的出站客流高峰, 晚高峰则就业热点的进站高峰先于就业热点的出站高峰, 站点的客流与其他站点的历史客流存在关联, 也就是时空关联。

1.2 与热点区域人数相关性

轨道交通客流与市区各热点区域的人流密度呈现很




图 1 深圳地铁客流 (各站点进出站平均) 周变化图




图 2 深圳地铁部分就业类、居住类大客流站点的客流日变化图 (以 2019 年 3 月 4 日星期一为例)

强的相关性。以皮尔逊相关系数 r 的绝对值来度量某一站点的一段客流序列 $x_i(i=t_0, \dots, t_0+n)$ 与某一点区域的一段人数序列 $y_{i+\Delta t}(i=t_0, \dots, t_0+n)$ 之间的相关系数

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma_x} \right) \left(\frac{y_{i+\Delta t} - \bar{y}}{\sigma_y} \right) \quad (1)$$

式中: Δt 为两段序列之间的时滞, n 为序列长度。

$|r|$ 越接近 1, 说明序列间的线性相关程度越明显 (见图 3)。从图 3 可以发现, 客流序列与热点区域人数的相关不一定是时间上对齐, 当前客流序列可能与的 Δt min 之前的热点区域人数序列更加相关; 客流与热点区域的相关系数随时段发生变化, 结合图可以看到, 在站点客流较大时, 站点客流与热点区域的人数变化更为相关, 反之则相关性较低。

2 基于深度时空网络的客流短时预测模型构建

2.1 问题描述

用 $x_{\tau,s}^{in}$ 和 $x_{\tau,s}^{out}$ 分别表示第 τ 个时段内站点 s 的进站、出站客流量。为预测 $t+1$ 时段轨道线网各站点的客流量 $Y_{t+1} = (x_{t+1,1}^{in}, \dots, x_{t+1,m}^{in}, x_{t+1,1}^{out}, \dots, x_{t+1,m}^{out})$, 输入数据需要表达在短期内轨道线网客流在时间、空间两个维度上的特征, 需要的输入时空矩阵 X_t 的表达式为

$$X_t = \begin{pmatrix} x_{t-T,1}^{in} & \cdots & x_{t-T,1}^{in} & x_{t-T,1}^{out} & \cdots & x_{t-T,1}^{out} \\ x_{t-T,2}^{in} & \cdots & x_{t-T,2}^{in} & x_{t-T,2}^{out} & \cdots & x_{t-T,2}^{out} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ x_{t-1,1}^{in} & \cdots & x_{t-1,1}^{in} & x_{t-1,1}^{out} & \cdots & x_{t-1,1}^{out} \\ x_{t,1}^{in} & \cdots & x_{t,1}^{in} & x_{t,1}^{out} & \cdots & x_{t,1}^{out} \end{pmatrix} \quad (2)$$

式中: T 为输入数据的时间段总数, m 表示轨道站点数量。

一些外在因素对轨道站点客流具有显著影响, 如本文选取了时段、节假日与热点区域人数三者作为外部因素。如上面分析得到的, 不同时段下的热点区域人数与站点客流的相关性不同, 他们对客流产生的影响具有潜在的耦合作用。将他们结合起来作为预测输入, 可以为非常态环境下的出行模式需求精准预测提供基础。对节假日这样类别变量进行独热编码 (one-hot encoding),

得到外部因素矩阵 E , 在预测 $t+1$ 时刻的客流时输入的外部因素矩阵 E_t 可以表达为

$$E_t = (e_{t-T+1}, \dots, e_t)^T \quad (3)$$

式中: e_t 代表 t 时段内的外部因素取值进行编码后的向量表示。

最后, 对所有的输入数据都采用 min—max 归一化^[7] 进行处理, 使得输入数据被限定在 $[0, 1]$ 范围内, 从而消除奇异样本数据、各站点客流值范围不一导致带来的影响。

综上所述, 问题可以描述为: 对于包含 m 个站点的轨道线网, 给定历史客流序列 X_t 和外部因素序列 E_t , 输出未来客流量 \hat{Y}_{t+1} 使得其与真实值 Y_{t+1} 误差最小。

2.2 问题建模

建立一个深度学习网络来预测未来 $t+1$ 时段内的轨道交通网络各站点的客流量 Y_{t+1} (见图 4)。该网络主要由卷积层、循环层和自回归通道三部分构成, 可以捕捉多变量时间序列的时空关联并输出该多变量时间序列下一时刻的预测值。本文称之为 Spatial-temporal network (STNet), 其各组成部分在下面详细介绍。

2.3 卷积层

STNet 的第一层由一个没有池化层的单层卷积神经网络构成, 卷积层由 K 个滤波器构成, 其尺寸为 $w \times h$, 宽度 w 设置为输入的时间序列变量的个数。第 k 个滤波器对输入矩阵 X 进行的卷积运算可以表示为

$$h_k = \text{RELU}(W_k \times X + b_k) \quad (4)$$

式中: \times 表示卷积运算; W_k 、 b_k 为滤波器 k 的参数, 可以通过学习进行调整; RELU 为修正线性单元 (ReLU), $\text{RELU}(x) = \max(0, x)$ 。滤波器 k 卷积的结果 h_k 会是一个向量, 为保证 h_k 在表示时间维度的高度尺寸上依然为 T , 对 X 的上边界进行填充 (padding)。最后卷积层的输出是 $T \times K$ 的矩阵。

设置卷积层的目的就是提取线网中所有站点在给定时间范围内的客流的时空特征, 并对输入进行降维, 适应大规模的站点数量。卷积核的宽度在地铁站点客流预测场景下 $w = 2 \times m$, 即 2 倍的地铁站点数量。这样做的




图 3 大客流站点客流与热点区域人数序列的相关度 (以车公庙出站客流为例, 保留最相关的前 20 个热点区域)

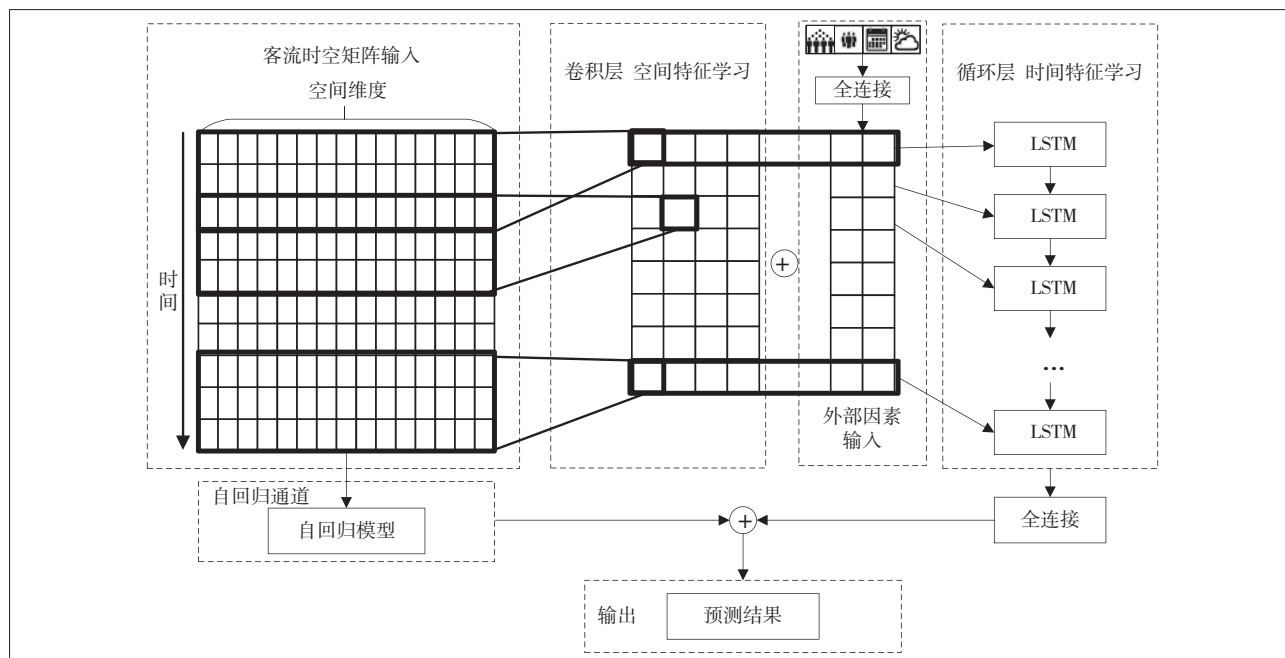


图4 STNet 示意图

理由在于,站点客流的空间关联强弱并不简单由站点地理位置的接近程度决定的,而由站点的功能、职住分布等复杂因素决定,多个地铁站点客流间的空间关联关系并不容易用一维或是二维空间中的欧氏距离表示,某站点的客流与相邻站点间的相关性可能远低于与其距离很远的另一站点。设置卷积核宽度为最大,使得卷积层的感受野覆盖所有序列,因此忽略各站点在空间上的接近程度,在整个地铁线网中考虑空间关联。卷积核的高度 h 决定了其在时间范围上的感受野。在我们的场景下(时间步长为15 min),发现合适设置的 h 值可以提升模型的效果(见图5)。图中可以看到,模型预测误差随着 h 增加先降低后升高,最佳取值在4左右,4个时间片段对应的时间跨度为60 min,侧面反映不同站点间进、出客流的关联主要集中在60 min之内。




图5 本文场景下模型预测误差随卷积核高度 h 的变化趋势

2.4 循环层

卷积层的输出,与外部因素输入 E_t 进行拼接后,输入到循环层。循环层由长短期记忆单元形成的LSTM网络构成,LSTM是为了解决循环神经网络RNN在时间维度上的梯度消失问题提出的^[8]。在一个LSTM单元中,除输入当前的输入向量 x_t 外,还接受 $t-1$ 时刻的单

元状态 c_{t-1} 作为输入,输出单元输出值 h_t 和当前时刻的单元状态 c_t ,单元内部包括了遗忘门 f_t 、输入门 i_t 、单元状态 c_t 和输出门 O_t 。LSTM单元内部各变量的具体计算方式如下^[8]:

$$\begin{aligned} f_t &= \sigma(W_{fh}h_{t-1} + W_{fx}X_t + b_f) \\ i_t &= \sigma(W_{ih}h_{t-1} + W_{ix}X_t + b_i) \\ \tilde{c}_t &= \tanh(W_{ch}h_{t-1} + W_{cx}X_t + b_c) \\ c_t &= f_t \circ c_{t-1} + i_t \circ \tilde{c}_t \\ O_t &= \sigma(W_{oh}h_{t-1} + W_{ox}X_t + b_o) \\ h_t &= O_t \cdot \tanh(c_t) \end{aligned} \quad (5)$$

式中:符号 \circ 为元素积。 σ 为Sigmoid激活函数^[9];各式中的 W 为权重矩阵; b 为偏置项,它们是可训练参数,且被各个LSTM单元共享。

2.5 自回归通道

深度神经网络中的卷积层和循环层部分由于非线性,其输出数值的数值范围对于输入数值的数值范围敏感性低。而地铁站点在短时段(如:15 min)内的客流在数值范围上具有大的变化范围,早晚高峰相比于平峰时提高了数倍至数十倍。因此,在客流突然发生大尺度变化时,将会显著降低预测精度。为了提高模型对输入数据尺度变化的敏感度,借鉴文献^[10]中提出的高速公路网络(highway network)的思想,为模型引入一条线性通道,作为模型的线性部分。该线性通道采用自回归模型,公式如下:

$$h_{t+1,i}^{AR} = \sum_{j=0}^{n_{hw}-1} W_j^{AR} y_{t-j,i} + b^{AR} \quad (6)$$

式中: $h_{t+1,i}^{AR}$ 变量 i 在时段 $t+1$ 的自回归模型预测值, n_{hw} 为输入时间窗的尺寸, W_j^{AR} 和 b^{AR} 为回归模型的参数, $y_{t-j,i}$ 为第 i 个时间序列在 $t-j$ 时段时的值。

因此,在STNet模型中,客流数据输入分两条路线,一条路线输入上面构建的深度神经网络,得到神经网络的预测结果 h_t^{NN} ;另外一条路线直接输入自回归模型,得到自回归预测结果 h_t^{AR} 。两部分预测结果相加,得到模型最终的预测结果:

$$Y_{t+1} = h_{t+1}^{NN} + h_{t+1}^{AR} \quad (7)$$

3 实例分析

3.1 数据来源

客流数据源为深圳通2019年3月前20天的IC卡刷卡数据。原始数据记录了深圳地铁各站点乘客进站、出站的时间,覆盖站点数量166个。热点人数数据采用同期腾讯热点区域人数数据,其以5 min的时间间隔统计了深圳全市61个热点区域的人数。

3.2 数据预处理

由于轨道交通在深夜至清晨之间停运或仅有少数站点有少量客流,数据存在大量的0值,数据的有效性低。因此,认为时间窗口2 h内,线网中客流为0的站点大于80%时,该时间窗口内的数据无效。对于无效时间窗口占比大于30%的日期,认为该日的的数据无效。对异常日、异常时间窗口内的数据进行剔除。

3.3 参数设置

本文采用TensorFlow 2.0深度学习框架来实现前面建立的STNet模型。经过大量试验,选定网络中的主要参数取值:输入的时间序列的长度 T 选择12,外部因素输入的维度为67(由所属时段、是否节假日、61个热点区域的人流数量拼接得到),外部因素全连接后的维度为16,卷积层滤波器尺寸 4×322 ,滤波器数量为128,LSTM隐藏层节点数设为256,自回归通道的时间窗尺寸 n_{hw} 为3。

本深度神经网络采用端到端的方式进行训练,采用Adam梯度下降算法^[11]来优化神经网络的参数。由于客流数据中的异常值很少,且客流大时预测精度的要求高,低客流时的预测精度的重要性较低,因此损失函数采用均方误差(MSE),其表达式为

$$\text{Loss} = \text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2 \quad (8)$$

式中: y_i 为真实值, \hat{y}_i 为预测值。

用均方根误差(RMSE)、平均绝对误差(MAE)和平均绝对百分比误差(MAPE)来评价模型的预测效果,它们的表达式为

$$\begin{aligned} \text{RMSE} &= \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \\ \text{MAE} &= \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \\ \text{MAPE} &= \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \end{aligned} \quad (9)$$

式中: y_i , \hat{y}_i 为站点 i 经过逆标准化处理后的实际的客流量和预测客流量。由于MAPE在实际客流较小时对于误差有放大效果(客流为0时为无穷大),本实验的MAPE计算只考虑 $y_i > 45$ 的情况(等价于平均每分钟客流3人)。

选取时间位于前80%的数据来训练模型(这其中的前80%的数据用于训练,后20%的数据用于验证),后20%的数据作为测试集,用于评价模型的预测效果。

3.4 预测结果

为了检验模型的有效性,选取15 min作为时间步长 ΔT ,选取四个常用的模型进行对比试验,分别是历史平均法(HA)、ARIMA、LSTM、梯度提升树(GBDT)。其中HA作为周期性预测的基线,根据对应周期中的历史客流平均值给出未来预测;GBDT是由一系列弱分类器进行加权集成生成预测结果的模型。同时,为了检验热点区域人数对于预测精度的影响,将本文模型分别按照不包含热点区域人数数据的STNet和包含热点区域人数数据的STNet_pop来进行预测。评价指标方面,除了根据全部站点、全部时段的客流预测量和真实值计算之外,还分别统计了工作日早晚高峰(7:30—9:30,17:30—19:30),以及大客流站点(月客流量排名前20%的33个站点)。最终结果取10次训练的平均值(见表1)。此外,选出客流量最大的站点之

表1 全部5种方式的预测误差汇总

比较范围	指标	HA	ARIMA	GBDT	LSTM	STNet	STNet_pop
全网客流	RMSE	378.84	247.77	149.82	127.65	109.95	109.05
	MAE	124.86	85.26	62.13	56.07	48.42	46.51
	MAPE	0.3425	0.244 1	0.188 5	0.177 5	0.159 4	0.152
工作日早晚高峰客流	RMSE	689.22	444.06	227.4	187.17	173.43	172.85
	MAE	251.49	165.96	100.26	82.95	72.66	72.79
	MAPE	0.374 2	0.25.44	0.165 6	0.143 5	0.127 3	0.129 4
大客流站点客流	RMSE	796.5	519.09	308.46	260.79	221.4	210.30
	MAE	328.23	220.53	159.09	140.34	117.66	108.92
	MAPE	0.391 7	0.269 9	0.209 7	0.190 9	0.162 1	0.142 6

中的五和、坪洲、高新园和车公庙，将他们在周一的进站、出站客流预测结果同真实值的比较，结果（见图6）。

表1中的结果可以看到，采用HA预测短时地铁客流并不可靠。ARIMA、GBDT这样对每个站点进行单独预测的模型精度较低，尤其是在高峰期和大客流站点。由于能够捕捉全网客流的时空关联，本文建立的STNet模型在三个范围内的预测误差上都稳定低于其他四种常用的方法，特别是在客流大的站点和高峰时段，精度优势更为明显，是有效且健壮的方法。从图6可以看到，STNet的预测结果与真实值之间的误差较小，在客流高峰时期也少有大的误差，预测客流的涨跌趋势与真实值同步度高，不存在明显的滞后问题。在为STNet模型的外部因素输入中添加热点区域人数数据后，大客流站点的客流预测精度有明显提升，而所有站点的精度整体水平提升有限，说明在当前场景下，热点区域人数

对于预知大客流站点的客流量更加有效。

4 结语

在本文中，建立了深度时空神经网络STNet来预测轨道线网尺度下的站点短时客流量。以深圳市轨道交通客流为例，分析了客流的时空关联和影响因素，包含热点区域人数和客流变化的关联，并作为参考指导了STNet的结构设计和参数取值。通过与四种常用模型的对比分析，展示了模型具备的高精度，能够很好地捕捉轨道线网中客流的时空关联，反映未来短时的客流变化趋势。无论是全网站点，还是轨道线网运营者和乘客都重点关注的大客流站点、通勤高峰时段，本模型都具备很好的精度和健壮度。在加入热点区域人数数据后，对于大客流站点的预测精度进一步上升。本模型能同时预测整个线网，具备搭建容易、训练高速、易于维护的优

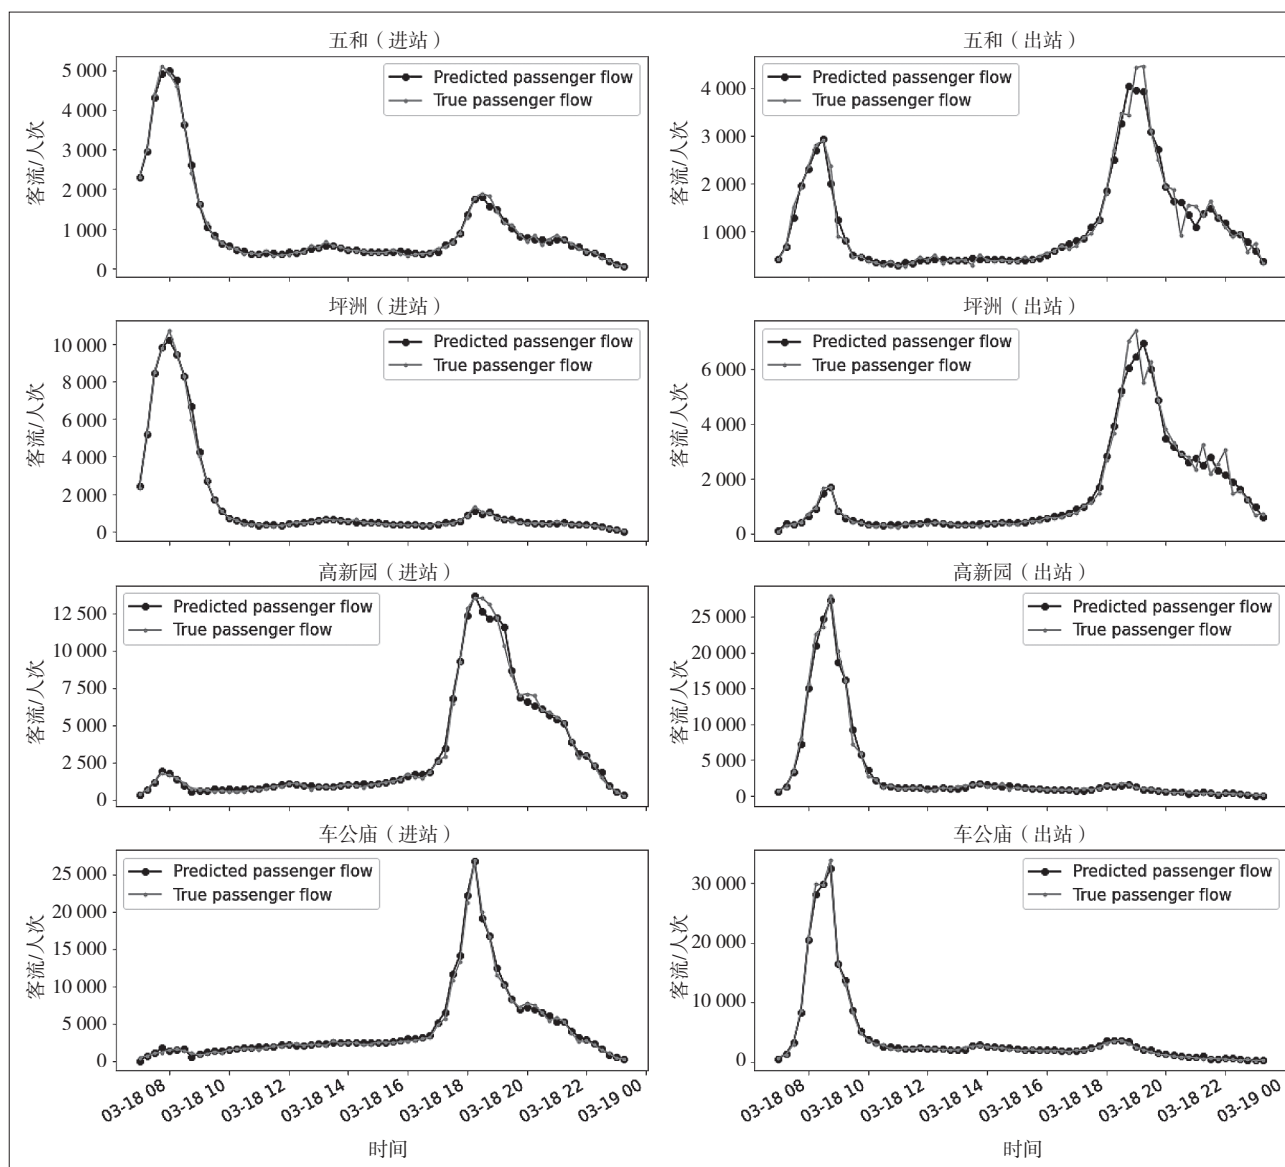


图6 部分大客流站点的客流预测值和真实值的比较

点, 可以通过此方法提供较为可信的轨道线网各站点客流预测, 为调整运营计划、应对突发客流、进行出行引导和信息服务、提高服务水平提供了依据。

参考文献:

- [1] BOX G E P, PIERCE D A. Distribution of residual autocorrelations in autoregressive-integrated moving average time series models[J]. Journal of the American Statistical Association, 1970.
- [2] 赵欣. 基于 GPR 与 KRR 的城市轨道交通短时客流预测研究[D]. 武汉: 武汉理工大学, 2019.
- [3] 伍宏伟. 基于隐马尔可夫模型的交通流预测研究[D]. 兰州: 兰州交通大学, 2019.
- [4] LIU Y, QIN Y, GUO J, et. al. Short-term forecasting of rail transit passenger flow based on long short-term memory neural network[C]//2018 International Conference on Intelligent Rail Transportation, ICIRT 2018.
- [5] ZHANG W, YU Y, QI Y, et. al. Short-term traffic flow prediction based on spatio-temporal analysis and CNN deep

learning[J]. Transportmetrica A: Transport Science, 2019.

- [6] YAO H, WU F, KE J, et al. Deep multi-view spatial-temporal network for taxi demand prediction[C]//32nd AAAI Conference on Artificial Intelligence, AAAI 2018.
- [7] PONNIAH P. Data Normalization[M]//Data Modeling Fundamentals.
- [8] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J]. Neural Computation, 1997.
- [9] SIBI P, ALLWYN JONES S, SIDDARTH P. Analysis of different activation functions using back propagation neural networks[J]. Journal of Theoretical and Applied Information Technology, 2013.
- [10] SRIVASTAVA R K, GREFF K, SCHMIDHUBER J. Highway NetWorks: Training Very Deep Networks[C]//NIPS'15 Proceedings of the 28th International Conference on Neural Information Processing Systems.
- [11] KINGMA D P, BA J L. Adam: A method for stochastic optimization[C]//3rd International Conference on Learning Representations, ICLR 2015 - Conference Track Proceedings.

(上接第 38 页)




图 7 改造后鼓楼与南侧步行街相连



图 8 改造前公交站点

参考文献:

- [1] 邵明, 戈晓宇. 供给侧改革背景下的城市绿色基础设施更新途径研究——以美国交通基础设施绿色化案例为例[J]. 工业建筑, 2017 (6): 178-183.
- [2] 杜恒. 城市双修中的交通改善与街道更新——路径、价值与实践[J]. 城市规划通讯, 2018 (6): 15-16.




图 9 改造后公交站点

- [3] 林箐. 缝合城市——促进城市空间重塑的交通基础设施更新[J]. 风景园林, 2017 (10): 14-26.
- [4] 彭敏. 北京城市交通基础设施更新规划初探[J]. 城市规划, 2018 (9): 88-92.
- [5] 曹庆锋, 林丽凡, 韦丽华, 等. 老城商业区用地更新与交通一体化研究——以合肥三孝口商圈为例[J]. 规划师, 2018 (S1): 77-80.
- [6] 毅超. 以圣迭戈和多伦多为例谈“完整街道”改造探索[J]. 山西建筑, 2016 (18): 25-26.
- [7] 陶一舟. 城市街道雨水的管理与利用——美国波特兰市“绿色街道”改造设计[J]. 园林, 2007 (6): 22-23.
- [8] 国外如何治理停车问题[J]. 汽车与安全, 2017 (11): 60-61.
- [9] C S. Removing Urban Freeways [EB/OL]. <https://www.planetizen.com/node/23300>.
- [10] 胡映东. 城市更新背景下的枢纽开发模式研究——以大阪站北区再开发为例[J]. 华中建筑, 2014 (6): 120-126.