

文章编号: 1001-4632 (2020) 04-0153-10

面向数据驱动的城市轨道交通短时客流预测模型

梁强升¹, 许心越², 刘利强²

(1. 广州地铁集团有限公司 运营事业总部, 广东 广州 510330;
2. 北京交通大学 轨道交通控制与安全国家重点实验室, 北京 100044)

摘要: 考虑城市轨道交通客流的时空交互关系, 提出一种融合循环门控单元和图卷积神经网络的城市轨道交通客流预测模型 (GCGRU)。首先, 分析短时客流在城市轨道交通网络中的空间关系, 建立图卷积神经网络提取不同车站客流的空间交互关系; 其次, 分析路网各车站客流的时间演化关系, 并利用循环门控单元刻画各车站客流数据的时间特征, 进而形成面向数据驱动的城市轨道交通路网短时客流预测模型。与传统方法相比, 该模型能较好地刻画路网各车站客流的时空相关性, 可以深度挖掘路网各车站客流变化的内在机理; 同时与既有的图卷积神经网络相比, 该模型提出了面向旅行时间的邻接矩阵, 能够挖掘客流数据与运行图数据的内在关系, 具有较高的精度和可解释性。最后, 以广州地铁典型车站的出站量预测为例, 验证该模型的有效性。结果表明: 该模型在整体预测性能和各车站的预测性能上都优于现有模型, 能较好地处理城市轨道交通客流的时空关系, 精准地预测路网各车站客流变化。此外, 通过邻接矩阵对预测精度影响的分析, 进一步验证该模型的性能。

关键词: 城市轨道交通系统; 数据驱动; 图卷积神经网络; 循环门控单元; 短时客流预测

中图分类号: U239.5; U293.13 **文献标识码:** A **doi:** 10.3969/j.issn.1001-4632.2020.04.18

1 引言

城市轨道交通以其运量大、速度快、可靠性高等运行特点, 已成为人口密集大城市的首选交通方式^[1]。我国城市轨道交通建设快速增长, 诱发了客流的急剧上升^[2], 导致轨道交通拥挤、服务质量下降。因此, 如何分析管理城市轨道交通客流, 特别是把握客流的短时变化规律已成为运营管理者提高城市轨道交通运行效率、缓解拥堵、提高服务质量迫切需要解决的问题^[3]。

城市轨道交通客流短时预测方法主要分为经典的统计模型和机器学习模型。经典的统计模型主要包括自回归综合移动平均 (ARIMA) 和指数平滑模型, 在早期得到了广泛的应用^[4]。例如, NI等^[5]将线性回归和ARIMA模型相结合对纽约地铁的短期客流进行了预测。WILLIAMS等^[6]基于季节ARIMA模型预测交通流量。然而, 这些统计方法大多属于线性的时间序列模型, 无法捕捉客流

的非线性变化, 导致其进行短时客流预测的误差较大^[7]。

为解决这一非线性预测难题, 机器学习方法应运而生。机器学习方法包括支持向量机、贝叶斯网络、 k -邻近算法、人工神经网络等。例如, SUN等^[8]提出了一种小波-支持向量机混合方法对北京地铁系统的换乘客流进行预测。ROOS等^[9]提出了一种利用不完整历史观测数据预测短期客流的动态贝叶斯网络方法。JIAO等^[10]提出了一种基于贝叶斯组合和非参数回归的改进卡尔曼滤波模型来预测北京地铁13号线高峰时段的客流。WEI等^[11]将经验分解模式与前馈神经网络相结合对短期客流进行预测, 结果表明该模型的预测精度优于ARIMA模型。LI等^[12]提出用径向基函数神经网络预测单站客流。然而, 所有这些模型都基于浅层结构, 无法捕获数据中的复杂非线性关系^[13-14]。

近年来, 循环神经网络、长短期记忆神经网络、门控递归单元神经网络和卷积神经网络由于在

收稿日期: 2020-03-31; 修订日期: 2020-06-08

基金项目: 国家自然科学基金资助项目 (71871012)

第一作者: 梁强升 (1963—), 男, 广东广州人, 高级工程师。E-mail: liangqiangsheng@gzmttr.com

通讯作者: 许心越 (1983—), 男, 河南信阳人, 副教授, 博士。E-mail: xxy@bjtu.edu.cn

捕捉时空关系方面具有优越的性能而受到广泛重视^[15-17]。在时间预测方面,循环神经网络利用输入序列和时间步长之间的连续反馈来获得时间相关性;而长短期记忆神经网络和门控递归单元神经网络,可以处理比循环神经网络更长的序列^[18]。同时,长短期记忆神经网络和门控递归单元神经网络都可以借助门控机制解决循环神经网络中的梯度消失和梯度爆炸问题^[17]。在空间预测方面,由于卷积神经网络的参数共享机制和连接稀疏性,使得卷积神经网络具有很好的空间信息特征。因此,结合长短期记忆神经网络、门控递归单元神经网络和卷积神经网络进行客流预测时,可以综合考虑客流的时空特征。例如,DU等^[19]提出一种深度不规则卷积残差长短期记忆神经网络对城市交通客流进行预测。DO等^[20]应用卷积神经网络和门控递归神经网络预测流量,该模型可以有效地提取动态时空特征。然而,这些既有的模型仅适用于单条线路的客流预测,无法考虑路网间的客流特征,难以实现对路网的客流预测。

近年来,一种擅长解决这类网络空间相关性问题的图卷积神经网络方法被提出,并得到了广泛关注。YU等人^[21]采用图卷积神经网络提取路网的时空相关性,从而对交通速度进行预测。虽然图卷积神经网络被证明具有较强的预测精度和可解释性,但如何结合城市轨道交通自动售检票系统(AFC)和时刻表数据利用图卷积神经网络方法进行短时客流预测的研究尚属空白。

综上,本文提出了一种新的融合循环门控单元的时空图卷积神经网络(GCGRU)模型来预测城市轨道交通的短时客流。本方法提出使用图卷积神经网络来描述短时客流的空间特征,特别是提出了基于旅行时间的邻接矩阵构建方法,并进一步融合循环门控单元描述客流间的时间特征,形成了考虑客流时空演化关系的城市轨道交通短时客流预测模型,具有较强的预测精度和可解释性。

2 数据驱动的短时客流预测方法

2.1 问题描述

设城市轨道交通网络用1个加权有向图 $G=(V,E)$ 表示: V 为城市轨道交通车站集合, E 为线路区间集合。设邻接矩阵为 A ,矩阵中各个元素的值代表每2个站点间的旅行时间;设站点特征矩阵

为 X :其中 X 的行数 N 为站点数量,列数 P 为车站的特征属性(即时间步长)。历史进站量为每个车站的特征属性, x_i 是每个站点在第 i 个时间步长的进站量。

不同车站类型(枢纽、通勤、商业等)和土地性质差异会产生不同的客流导向,导致不同站点在不同时段有不同的客流特征。土地性质及站点类型等因素造成进出站量的变化,并可通过进站量来反映这些变化,因此进站量常被作为主要输入变量进行出站量的预测。

某一车站的客流经过列车运输分散到路网各个相关车站,不同车站的客流经过特定列车运输到达同一个目的车站,因此车站的进站客流会影响到其他车站的出站客流。本文根据城市轨道交通路网中各站点的历史进站量来预测未来的出站量。因此,城市轨道交通短时客流预测问题可转化为根据邻接矩阵 A 和节点的进站客流量特征矩阵 X 来学习映射函数 f ,即

$$[\hat{y}_{i+1}, \dots, \hat{y}_{i+T}] = f(A; [x_{i-p+1}, \dots, x_{i-1}, x_i]) \quad (1)$$

式中: $\hat{y}_{i+1}, \dots, \hat{y}_{i+T}$ 为相应的出站量(预测值), $x_{i-p+1}, \dots, x_{i-1}, x_i$ 为每个节点在每个时间步长 t 内的进站量。

2.2 面向数据驱动的短时客流预测模型

本节提出面向数据驱动的短时客流预测方法分为2部分:①用来提取序列空间特征的图卷积神经网络GCN(Graph Convolutional Networks)神经网络;②用来提取时间特征的门控递归单元神经网络GRU(Gate Recurrent Unit)神经网络。第1部分的输出作为第2部分GRU的输入。具体模型框架如图1所示。

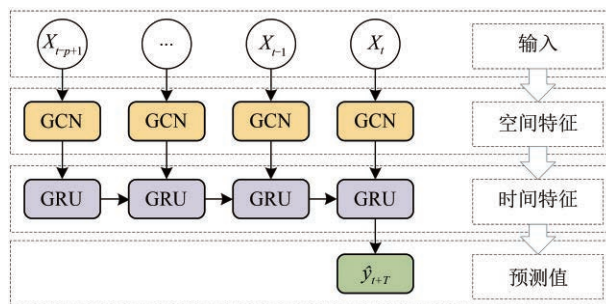


图1 模型框架

2.2.1 空间图卷积网络模型

图中 $G=(V,E)$ 具有2种特征:节点特征和结构特征(节点之间的依赖关系)。GCN神经网络有2种:一种基于顶点域或空间域,另一种基于频域

或谱域。本文采用基于空间域的GCN来学习图的结构特征。

GCN模型有2个输入：邻接矩阵 A 和进站客流特征矩阵 X 。邻接矩阵 A 的表达式为

$$A_{ij} = \begin{cases} \frac{t_{ij}}{\sum_{j=1}^N t_{ij}}, & \text{如果 } (v_i, v_j) \in E \\ 0, & \text{否则} \end{cases} \quad (2)$$

式中： t_{ij} 为乘客从车站 i 到车站 j 的平均旅行时间。

GCN的层与层之间的传播方式可表示为

$$H^{(l+1)} = g(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \quad (3)$$

式中： $H^{(l)}$ 、 $H^{(l+1)}$ 分别为第 l 层和第 $(l+1)$ 层的特征矩阵； g 为斜坡激活函数； \tilde{A} 为邻接矩阵与单位矩阵的和， $\tilde{A} = A + I$ ； \tilde{D} 为 \tilde{A} 的度矩阵； $W^{(l)}$ 为第 l 层的权矩阵。初始层 $H^{(0)}$ 的特征矩阵为进站客流量特征矩阵 X ，且 g 和 \tilde{D} 可由下面公式计算

$$g(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \quad (4)$$

$$\tilde{D}_{ij} = \begin{cases} \sum_{j=1}^N \tilde{A}_{ij}, & i = j \\ 0, & i \neq j \end{cases} \quad (5)$$

由于GCN层的最佳数量是2~3，本文选取2层GCN模型，故可将式(3)重新表述为

$$H^{(2)} = g(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} g(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X W^{(1)}) W^{(2)}) \quad (6)$$

2.2.2 GRU模型

GRU用以捕捉预测数据间的时间信息，它有2个门：更新门（表示为 z_t ）和重置门（表示为 r_t ），如图2所示。更新门决定了客流预测保留多少以前的状态，重置门决定了新输入与前一状态融合的程度。更新门的值越大，则前一个时间步长内的信息被带入的就越多。重置门的值越小，则前一时间步长内的信息越容易被忽略。




图2 GRU的计算图

GRU的输入用矩阵 $X' = [x'_{t-p+1}, x'_{t-p+2}, \dots, x'_t]$

表示，是 $H^{(2)}$ （GCN模型的输出）的转置矩阵。

每个GRU的状态计算如下。

$$r_t = \sigma(W_{rh}h_{t-1} + W_{rx}x'_t + b_r) \quad (7)$$

$$z_t = \sigma(W_{zh}h_{t-1} + W_{zx}x'_t + b_z) \quad (8)$$

$$\tilde{h}_t = \tanh(W_{hh}(r_t h_{t-1}) + W_{hx}x'_t + b_h) \quad (9)$$

$$h_t = (1 - z_t)h_{t-1} + z_t\tilde{h}_t \quad (10)$$

式中： W_{rh} 、 W_{rx} 、 W_{zh} 、 W_{zx} 、 W_{hh} 、 W_{hx} 为加权矩阵，控制着隐藏层到相应的输入的连接； h_{t-1} 为第 $t-1$ 个时间步长的隐藏状态； b_r 、 b_z 、 b_h 为偏置项； \tilde{h}_t 为当前记忆内容； h_t 是第 t 个时间步长的隐藏状态，也是GRU的输出； σ 是sigmoid函数， σ 和 \tanh 是由以下公式定义的非线性激活函数。

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (11)$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (12)$$

2.2.3 损失函数

在模型训练过程中，目标是城市轨道交通网络实际客流量与预测值之间的误差最小化，即模型的损失函数为

$$f_{loss} = \|y_t - \hat{y}_t\| + \lambda L_{reg} \quad (13)$$

式中： $\|y_t - \hat{y}_t\|$ 为最小化实际客流与预测值之间的误差； L_{reg} 是L2正则化，用来避免过拟合； λ 是超参数。

本文提出的模型具有以下优点：

(1) 可以通过邻接矩阵学习城市轨道交通网络系统中各站点之间的空间相关性，解决了传统CNN模型不能预测网络层次客流的问题。目前应用于道路网络层次的GCN都是基于地理距离来构建邻接矩阵，而本文基于旅行时间来构建邻接矩阵，能更准确地学习各站点之间的空间关系。

(2) 采用的GRU模型通过更新门和重置门对历史客流信息进行筛选，以解决序列之间的依赖关系，实现对较长时间序列的精准预测。此外，GRU中的2个门控单元均采用了非线性函数，能够有效识别客流中的复杂非线性关系。

(3) 本模型结合GCN和GRU模型可以实现城市轨道交通全网的时空客流预测，与传统只考虑时间关系的模型相比，本模型的预测精度更高、解释性更强。此外，本模型采用数据驱动的方法来学习城市轨道交通网络中的时空关系，具有较强的稳定性和鲁棒性。

3 预测模型及分析

3.1 数据描述

选取广州地铁6个重要的就业型站点为例,对客流预测模型进行有效性验证。所选取的车站具有客流量较大或是重要的换乘站等特点,即:客村、杨箕、珠江新城、体育西路、公园前、琶洲,如图3所示。预测数据采用2017年5月15日至5月27日的广州地铁路网数据、AFC数据(见表1)和时刻表数据,这些数据含周末的客流量。基于以上数据构建预测模型相关的2个矩阵。

(1) 描述城市轨道交通车站间空间关系的 6×6 邻接矩阵。矩阵的行表示车站,矩阵中的值为乘客在站与站之间的平均旅行时间,可由时刻表数据确定。

(2) 描述每个车站进站和出站客流随时间变化的特征矩阵和标签矩阵。矩阵的行表示一个时间步长内各站点的客流量,列表示在不同时间段内各站



图3 典型的广州地铁车站示意图

点的客流量。其中:客流量是根据AFC数据进行15 min粒度统计后的量。进一步利用最小-最大规范化技术,将矩阵内的数值规范化到 $[0, 1]$ 范围内。

表1 AFC数据样本

卡账户	进站				出站			
	线路	车站	日期	时刻	线路	车站	日期	时刻
1127515451831778	8号线	客村	2017/5/15	8:25:07	3号线	体育西路	2017/5/15	8:44:54
3127563708354679	8号线	客村	2017/5/15	8:19:43	3号线	体育西路	2017/5/15	8:43:06
...

3.2 评价指标

选取均方根误差(S_{RMSE})、平均绝对误差(S_{MAE})、精度(S_{Acc})、决定系数(R^2)和可释方差得分(S_{Var})5个评价指标来评价模型的性能,它们的计算公式如下。

$$S_{\text{RMSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (14)$$

$$S_{\text{MAE}} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (15)$$

$$S_{\text{Acc}} = 1 - \frac{\|y_i - \hat{y}_i\|_F}{\|y\|_F} \quad (16)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (17)$$

$$S_{\text{Var}} = 1 - \frac{\text{Var}\{y_i - \hat{y}_i\}}{\text{Var}\{y\}} \quad (18)$$

在上述评价指标中, S_{RMSE} 和 S_{MAE} 都是用来度量预测误差的,两者都是绝对指标,且值越小,预测性能越好。 S_{Acc} , R^2 和 S_{Var} 都是相对指标,值越大,预测性能越好。

3.3 参数调整

GCGRU模型的超参数主要包括学习率、批大小、训练次数、隐藏单元数和正则化参数。在本次实验中,学习率初始值设为0.001,并用Adam优化器自动优化;批量大小一般设置成2的 n 次方,批量大小越大,模型精度越低、训练速度越快,通过手动调节并综合考虑精度和训练速度,最终将其设为64;当训练次数达到2 000时,模型的精度不再上升,因此将训练次数设为2 000;将 λ 分别设定为0, 0.1, 0.01, 0.001, 0.001 5, 0.002,当 λ 为0.001 5时,模型精度达到最高,因此将 λ 设置为0.001 5。以上参数对模型5个评价指标的影响都很小,因此不再进一步分析。

由于隐藏单元数对深度学习模型的5个评价指标有很大的影响^[14],因此本文对不同数量隐藏单元下的GCGRU模型进行了实验(分别设定8, 16, 24, 32),以获取最优的隐藏单元数。实验结果如图4所示。随着隐藏单元数的增加, S_{RMSE} 和 S_{MAE} 先减少后增加, S_{ACC} , R^2 和 S_{Var} 的值呈现相反的变化趋势。当隐藏单元数为24时, S_{RMSE} 和 S_{MAE} 达到最小, S_{ACC} , R^2 和 S_{Var} 的值同时达到了最大。因此,最优的隐藏单元数为24。




图4 不同隐藏单元数下评价指标的变化

3.4 模型评价

选取以下模型作为基线模型进行对比分析。

(1) ARIMA模型是典型的时间序列模型,擅于处理时间序列数据。该模型有3个整数型的参数 p , d , q , 该模型通过自动遍历不同的 p , d , q 组合, 确定最优组合为: $p=1$, $d=1$, $q=1$ 。

(2) 支持向量机 (SVR): SVR是经典的机器学习模型,它利用历史数据对模型进行训练,得到输入和输出之间的关系,因此常用于预测客流。选取带有线性核的SVR模型作为比较模型。

(3) 前馈神经网络 (BP): BP模型是基本的神经网络模型,能够处理非线性关系。BP模型有学习率(自动调节)、批量大小、训练次数、正则化系数 λ 以及隐藏单元数5个参数,其调节过程与3.3节所叙方法一样。调参结果为:批量大小为64,训练次数为2 000, λ 为0.001 5,隐藏单元数为24。

(4) GRU: GRU是深度学习模型,具有捕捉时间信息的能力。GRU的参数与BP模型一样,调

节结果为:批量大小为64,训练次数为2 000, λ 为0.001 5,隐藏单元数为24。

本文在不同预测步长下利用以上各种模型进行了客流预测,结果见表2。

3.4.1 整体预测结果

首先,将本文提出的GCGRU模型与其余4个模型 (ARIMA, SVR, BP和GRU模型) 的 S_{RMSE} 进行了比较,不同模型的 S_{RMSE} 比较结果如图5所示。对于15 min的预测步长,GCGRU的 S_{RMSE} 分别比ARIMA, SVR, BP和GRU模型的 S_{RMSE} 降低了80.5%, 77.4%, 33.7%和28.9%。因此,本文提出的GCGRU比4个对比模型的预测误差都低。




图5 5个模型的均方根误差比较结果

其次,将GCGRU模型与不具备时间信息捕捉能力的非线性模型 (SVR和BP模型) 进行了比较分析。从表2中可以看出,SVR模型的 S_{ACC} 太小以至于可被忽略,因此,只将GCGRU模型的精度 S_{ACC} 与BP模型和GRU模型进行对比,如图6所示。对于15 min的预测步长,GCGRU模型的 S_{ACC} 分别比BP模型和GRU模型的 S_{ACC} 提高了10.4%和8.1%。因此,本文提出的GCGRU模型比SVR模型和BP模型的预测精度都高。




图6 模型精度比较

最后,将GCGRU模型与不具备空间信息捕捉能力的GRU模型进行了对比,结果如图7和图8所示。对于15, 30, 45和60 min的预测时间步长,GCGRU模型的 S_{RMSE} 比GRU模型分别降低了28.9%, 21.4%, 29.8%和29.8%, S_{ACC} 分别提

表2 GCGRU模型和基线模型预测性能的比较结果

预测步长/min	预测模型	不同模型的评价指标值				
		S_{RMSE}	S_{MAE}	S_{ACC}	R^2	S_{Var}
15	ARIMA	1 297.190	809.230	*	*	*
	SVR	1 115.224	740.866	*	*	*
	BP	380.452	285.935	0.765	0.890	0.890
	GRU	354.799	235.566	0.780	0.904	0.908
	GCGRU	252.330	180.410	0.844	0.952	0.952
30	ARIMA	1 398.260	887.660	*	*	*
	SVR	1 347.553	823.729	*	*	*
	BP	437.854	316.412	0.730	0.854	0.855
	GRU	366.689	246.620	0.774	0.898	0.899
	GCGRU	288.240	201.952	0.822	0.937	0.939
45	ARIMA	1 443.780	916.020	*	*	*
	SVR	1 412.340	896.740	*	*	*
	BP	474.398	358.213	0.708	0.830	0.852
	GRU	436.256	280.153	0.731	0.856	0.863
	GCGRU	306.157	228.712	0.811	0.929	0.937
60	ARIMA	1 593.560	997.330	*	*	*
	SVR	1 559.590	985.980	*	*	*
	BP	543.310	412.201	0.666	0.777	0.783
	GRU	427.335	271.760	0.737	0.862	0.873
	GCGRU	300.071	208.229	0.816	0.932	0.932

注：“*”表示评价指标的值太小，即预测结果太差，因此可以被忽略。

高了8.1%，6.3%，10.9%和10.6%。因此，GRU和GCN融合模型实现了数据中时空关系的高效挖掘，预测效果比既有的GRU模型好。




图7 GCGRU模型与GRU模型的均方根误差比较




图8 GCGRU模型与GRU模型的预测精度比较

综上，与所有基线模型相比，本文提出的GCGRU模型在不同的评价指标和预测时间步长情况下的表现性能都最好。

3.4.2 单个车站预测性能

将GCGRU模型与GRU模型在每个车站的预测性能进行了进一步的比较分析，得到图9和图10。由图可知，对于每个车站而言，GCGRU模型的 S_{RMSE} 比GRU模型的都低， R^2 GRU模型的也高；特别在公园前车站，GCGRU模型与GRU模型的 S_{RMSE} 差距最大，前者相对于后者降低了47.8%；在体育西路车站，GCGRU模型与GRU模型的 R^2 差距最大，前者相对于后者提升了23.9%。此外，GCGRU模型预测结果中琶洲站的 S_{RMSE} 最高， R^2 最低。这主要是因为琶洲车站附近有展览中心，经常会有展览活动，因此预测效果不是很好，未来需要进一步挖掘时空关系和外在因素。




图9 GCGRU模型和GRU模型在不同车站的均方根误差比较


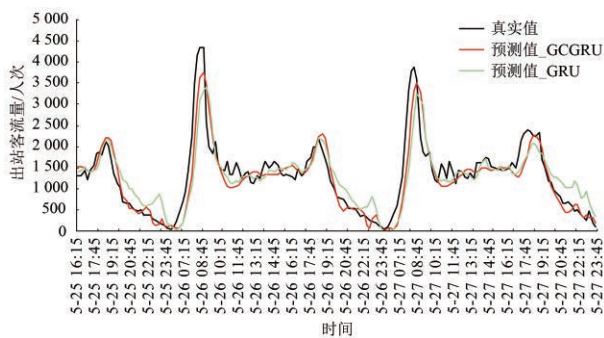



图10 GCGRU模型和GRU模型不同车站决定系数比较


图11为6个车站的2017年5月客流拟合图。由图可知：琶洲站和珠江新城站的客流呈单峰趋势，且都为早高峰；其余车站都呈现早晚双峰趋势。进一步分析，在琶洲站，GRU模型在高峰时期的预测值比真实值低，如图11(c)所示；而在杨箕站，GRU模型在高峰时期的预测值又比真实值高，如图11(e)所示。因此，GCGRU模型的预测效果优于GRU模型。




(a) 公园前




(b) 客村



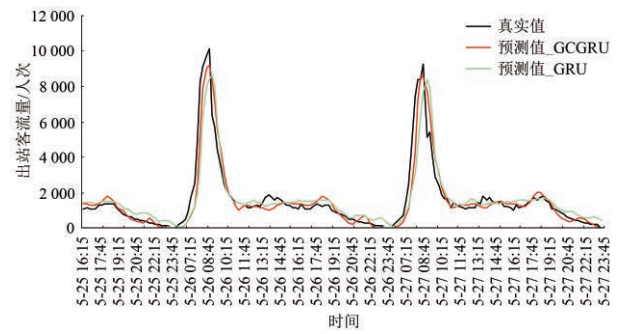
(c) 琶洲



(d) 体育西路



(e) 杨箕



(f) 珠江新城

图11 不同车站的客流拟合曲线图

3.4.3 邻接矩阵影响

为了验证旅行时间邻接矩阵的有效性，将GCGRU模型与地理邻接矩阵的模型进行了比较。令基于地理邻接矩阵的模型为GCGRU*，比较GCGRU与GCGRU*在不同预测步长下的 S_{RMSE} 与 S_{ACC} ，如图12所示。针对15, 30, 45和60 min的预测步长，GCGRU比GCGRU*的 S_{RMSE} 分别减少了6.1%，2.7%，2.4%和5.3%； S_{ACC} 分别增加了0.8%，1.0%，1.0%和3.0%。由此可见，GCGRU的预测性能更好，因此基于旅行时间构建的邻接矩阵更适合于城市轨道交通网络的短期客流预测。

4 结 语

本文提出了1种新的融合循环时空单元的时空




图12 GCGRU与GRU预测的均方根误差和精度比较

图卷积神经网络模型 (GCGRU) 来预测城市轨道交通短时客流。循环门控单元用以提取时间特征,

图卷积神经网络用以提取空间特征。以广州地铁路网6个车站的短时客流预测为例进行模型的有效性验证。结果表明, 该模型的预测性能优于ARIMA, SVR, BP和GRU等基线模型, 对于整体预测结果来说, 精度至少提高了6.3%, 最多可提高80.5%。对于单站客流预测结果来说, 精度至少提高了1.4%, 最多可提高23.9%。因此, 本文提出的模型能够有效地刻画各车站客流间的时空演化关系, 具有精度高、解释性强等特点, 可以较好地城市轨道交通日常客流组织和管理提供辅助决策。

本文提出的模型是1个静态的空间卷积网络模型, 其邻接矩阵不会随着时间而改变。但实际上, 各站点之间的空间关系会随时间变化。因此未来可尝试将动态的GCN与GRU相结合来预测客流。本文提出的模型目前只考虑了邻接矩阵和进站客流对出站客流的影响。实际上, 出站客流还受到周期、时段以及天气等因素的影响, 未来可将这些因素考虑到模型中, 以提高模型精度。此外, 未来本模型还可以考虑应用在进站量预测上。

参 考 文 献

- [1] LIU Y, LIU Z, JIA R. A Deep Learning Based Architecture for Metro Passenger Flow Prediction [J]. Transportation Research Part C: Emerging Technologies, 2019, 101: 18-34.
- [2] 刘莎莎, 姚恩建, 李斌斌, 等. 基于行为分析的突发事件下城轨站间客流分布预测[J]. 铁道学报, 2018, 40(9): 22-29. (LIU Shasha, YAO Enjian, LI Binbin, et al. Forecasting Passenger Flow Distribution between Urban Rail Transit Stations Based on Behavior Analysis under Emergent Events [J]. Journal of the China Railway Society, 2018, 40 (9): 22-29. in Chinese)
- [3] SHANG P, LI R, GUO J, et al. Integrating Lagrangian and Eulerian Observations for Passenger Flow State Estimation in an Urban Rail Transit Network: A Space-Time-State Hyper Network-Based Assignment Approach [J]. Transportation Research Part B: Methodological, 2019, 121: 135-167.
- [4] 白丽. 城市轨道交通常态与非常态短期客流预测方法研究[J]. 交通运输系统工程与信息, 2017, 17(1): 127-135. (BAI Li. Urban Rail Transit Normal and Abnormal Short-Term Passenger Flow Forecasting Method [J]. Journal of Transportation Systems Engineering and Information Technology, 2017, 17 (1): 127-135. in Chinese)
- [5] NI M, HE Q, GAO J. Forecasting the Subway Passenger Flow under Event Occurrences with Social Media [J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 18 (6): 1623-1632.
- [6] WILLIAMS B M, HOEL L A. Modeling and Forecasting Vehicular Traffic Flow as a Seasonal ARIMA Process: Theoretical Basis and Empirical Results [J]. Journal of Transportation Engineering, 2003, 129 (6): 664-672.
- [7] GU Y, LU W, XU X, et al. An Improved Bayesian Combination Model for Short-Term Traffic Prediction with Deep Learning [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21 (3): 1332-1342.
- [8] SUN Y, LENG B, GUAN W. A Novel Wavelet-SVM Short-Time Passenger Flow Prediction in Beijing Subway System [J]. Neurocomputing, 2015, 166: 109 - 121.

- [9] ROOS J, BONNEVAY S, GAVIN G. Short-Term Urban Rail Passenger Flow Forecasting: A Dynamic Bayesian Network Approach [C]//2016 15th IEEE International Conference on Machine Learning and Applications (ICMLA). Anaheim: IEEE, 2016: 1034-1039.
- [10] JIAO P P, LI R M, SUN T, et al. Three Revised Kalman Filtering Models for Short-Term Rail Transit Passenger Flow Prediction [J]. Mathematical Problems in Engineering, 2016, 2016: 1-10.
- [11] WEI Y, CHEN M C. Forecasting the Short-Term Metro Passenger Flow with Empirical Mode Decomposition and Neural Networks [J]. Transportation Research Part C: Emerging Technologies, 2012, 21 (1): 148-162.
- [12] LI H, WANG Y, XU X, et al. Short-Term Passenger Flow Prediction under Passenger Flow Control Using a Dynamic Radial Basis Function Network [J]. Applied Soft Computing, 2019, 83: 1-13.
- [13] 杨静, 朱经纬, 刘博, 等. 基于组合模型的城市轨道交通短时客流预测[J]. 交通运输系统工程与信息, 2019, 19 (3): 119-125.
(YANG Jing, ZHU Jingwei, LIU Bo, et al. Short-Term Passenger Flow Prediction for Urban Railway Transit Based on Combined Model [J]. Journal of Transportation Systems Engineering and Information Technology, 2019, 19 (3): 119-125. in Chinese)
- [14] 周家中, 张殿业. 基于空间加权的LS-SVM城市轨道交通车站客流量预测[J]. 铁道学报, 2014, 36(1): 1-7.
(ZHOU Jiazhong, ZHANG Dianye. Directed Ridership Forecast Model of Urban Rail Transit Stations Based on Spatial Weighted LS-SVM [J]. Journal of the China Railway Society, 2014, 36 (1): 1-7. in Chinese)
- [15] HUANG W, SONG G, HONG H, et al. Deep Architecture for Traffic Flow Prediction: Deep Belief Networks with Multitask Learning [J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15 (5): 2191-2201.
- [16] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-Based Learning Applied to Document Recognition [J]. Proceedings of the IEEE, 1998, 86 (11): 2278-2324.
- [17] WEN H, LIU Y, CHE W, et al. Sequence-to-Sequence Learning for Task-Oriented Dialogue with Dialogue State Representation [J]. Transportation Research Part C: Emerging Technologies, 2018, 107: 287-300.
- [18] FU R, ZHANG Z, LI L. Using LSTM and GRU Neural Network Methods for Traffic Flow Prediction [C]// 2016 31st Youth Academic Annual Conference of Chinese Association of Automation (YAC). Wuhan: IEEE, 2016: 324-328.
- [19] DU B, PENG H, WANG S, et al. Deep Irregular Convolutional Residual LSTM for Urban Traffic Passenger Flows Prediction [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21 (2): 972-985.
- [20] DO L N, VU H L, VO B Q, et al. An Effective Spatial-Temporal Attention Based Neural Network for Traffic Flow Prediction [J]. Transportation Research Part C: Emerging Technologies, 2019, 108: 12-28.
- [21] YU B, LEE Y J, SOHN K. Forecasting Road Traffic Speeds by Considering Area-Wide Spatio-Temporal Dependencies Based on a Graph Convolutional Neural Network [J]. Transportation Research Part C: Emerging Technologies, 2020, 114: 189-204.

Data-Driven Short-Term Passenger Flow Prediction Model for Urban Rail Transit

LIANG Qiangsheng¹, XU Xinyue², LIU Liqiang²

(1. Operations Division, Guangzhou Metro Group Co., Ltd., Guangzhou Guangdong 510330, China;

2. State Key Lab of Rail Traffic Control & Safety, Beijing Jiaotong University, Beijing 100044, China)

Abstract: Considering the spatiotemporal interaction of the passenger flow of urban rail transit, a new passenger flow prediction model (GCGRU) for urban rail transit is proposed, which combines gated recurrent unit and

graph convolution neural network. Firstly, the spatial relationship of short-term passenger flow in urban rail transit network is analyzed, and graph convolution neural network is established to extract the spatial interaction relationship of passenger flow at different stations. Secondly, the time evolution relationship of passenger flow at each station of road network is analyzed. Gated recurrent unit is applied to describe the time characteristics of passenger flow data of each station, and then a data-driven short-term passenger flow prediction model of urban rail transit network is formed. Compared with the traditional methods, this model can better describe the spatiotemporal correlation of passenger flow at each station in the road network, and can deeply explore the internal mechanism of passenger flow change at each station in the road network. At the same time, compared with the existing graph convolution neural network, a travel time oriented adjacency matrix is proposed in this model, which can mine the internal relationship between passenger flow data and operation graph data with higher accuracy and interpretability. Finally, the validity of the model is verified by the outbound forecast of a typical station in Guangzhou Metro. Results show that this model is better than the existing models in the overall prediction performance and the prediction performance of each station. It can better deal with the spatiotemporal relationship of urban rail transit passenger flow and accurately predict the change of passenger flow at each station in the road network. In addition, the influence of adjacency matrix on prediction accuracy is analyzed, and the performance of the proposed method is further verified.

Key words: Urban rail transit system; Data-driven; Graph convolution neural network; Gated recurrent unit; Short-term passenger flow prediction

(责任编辑 周新军)